

Rúbrica Proyecto Final - Compresión de archivos de texto

Estructuras de Datos
Facultad de Ingenierías - Universidad Tecnológica de Pereira
Ingeniería de Sistemas y Computación

1 Requerimientos

- Implementar el algoritmo de **Huffman Coding** para la compresión de un archivo con extensión .txt a un archivo con extensión .bin y extracción (descompresión) de datos textuales a partir de un archivo con formato .bin.
- Implementar el algoritmo de compresión **LZ77** para la compresión de un archivo con extensión .txt a un archivo con extensión .bin y extracción (descompresión) correspondiente.
- Implementar un sistema integrado que combine ambos algoritmos de manera secuencial . Es decir, dado un archivo de texto:
 - Aplicar inicialmente el algoritmo LZ77.
 - Posteriormente, aplicar Huffman Coding sobre el resultado.
 - Permitir la extracción de un archivo comprimido que haya sido producido a partir de este método
- Para cada uno de los numerales anteriores se debe garantizar la reconstrucción **sin pérdidas (lossless)** de la información original al extraer.
- Implementar funcionalidades para evaluar el desempeño de cada uno de los anteriores numerales, considerando los siguientes criterios:
 - Tasa de compresión.
 - Tiempo de ejecución.
- Elaboración de un reporte de resultados que incluya los resultados recolectados en el numeral anterior así como sus conclusiones con relación a estos y al proceso de desarrollo.
- El proyecto debe incluir una **interfaz basada en terminal** desde la cual permita:
 - Elegir la tarea de compresión/extracción a ejecutar (Compresión/Extracción).
 - Seleccionar el archivo sobre el cual se va a realizar el proceso.
- El proyecto debe ser presentado y sustentado de manera grupal durante la última semana de clase.
- La implementación debe realizarse en lenguaje C/C++.

Nota: NO se requiere que se maneje persistencia entre ejecuciones del programa; los procesos de compresión y extracción de archivo se van a realizar en una sola instancia de ejecución.

2 Bonus

- Implementación del algoritmo **LZMA** (Lempel-Ziv-Markov chain algorithm), incorporando el uso de **cadena de Markov**, como en el caso de uso de 7Z. Se valorará la integración con los requerimientos anteriores. (+2.5).
- La implementación de herramientas adicionales que demuestren creatividad y entendimiento del problema y alcance del proyecto, así como mejoras al mismo serán consideradas como bonificación proporcionalmente.

3 Lecturas recomendadas

3.1 Huffman Coding

- Moffat, A. (2019). Huffman coding. ACM Computing Surveys (CSUR), 52(4), 1-35.
- https://www.w3schools.com/dsa/dsa_ref_huffman_coding.php

3.2 LZ77

- https://learn.microsoft.com/en-us/openspecs/windows_protocols/ms-wusp/fb98aa28-5cd7-407f-8869-a6cef1ff1ccb

3.3 LZMA

- <https://www.7-zip.org/sdk.html>